Bogumił Wierzchowski 291498

Analiza sygnału w dziedzinie czasu i częstości

Ćwiczenie nr. 1

1. Wstęp

Celem ćwiczenia jest zbadanie sygnału nagranego w pliku *chord.wav* w dziedzinie czasu i częstości, określenie jego typu oraz wykonanie wykresów w funkcji czasu i widma mocy, a także stworzenie metody identyfikującej podane nagranie.

Użyte oprogramowanie: *Python ver. 3.9.7*

Użyte biblioteki: *numpy, scipy, matplotlib, pandas*

2. Kod źródłowy

```
import numpy as np
from scipy.io import wavfile
import scipy.io
import matplotlib.pyplot as plt
import librosa.display
import scipy.signal as sig
from scipy.signal import find_peaks
import pandas as pd

wav_fname = 'data/acc1/acc1/chord.wav'
samplerate, data = wavfile.read(wav_fname)

plt.rcParams["figure.figsize"] = [15, 8]
plt.rcParams['font.size'] = '13'

length = data.shape[0] / samplerate
time = np.linspace(0., length, data.shape[0])

plt.plot(time,data)
plt.xlabel("Czas [s]")
plt.ylabel("Amplituda")
```

```
plt.title('Sygnał w dziedzinie czasu')
plt.show()

window = np.hamming(len(data))
widmo_amp = np.abs(np.fft.rfft(data * window)) / (len(data)/2)
f = np.fft.rfftfreq(len(data), 1/samplerate)

plt.plot(f, widmo_amp)
plt.xlabel('częstotliwość [Hz]')
plt.ylabel('amplituda widma')
plt.title('Transformata Fouriera z oknem Hamminga')
plt.xlim(-30,4000)
#plt.ylim(0, 1000)
plt.show()

widmo_dB = 20 * np.log10(widmo_amp ** 2)

plt.plot(f, widmo_dB)
plt.xlabel('częstotliwość [Hz]')
plt.ylabel('moc [dB]')
plt.title('Widmo mocy sygnału')
#plt.xlim(-10,350)
#plt.ylim(0, 1000)
plt.show()

plt.plot(f, widmo_dB)
plt.xlabel('częstotliwość [Hz]')
plt.ylabel('moc [dB]')
plt.title('Widmo mocy sygnału dla przedziału 16Hz - 4kHz')
plt.xlim(16,4000)
plt.ylim(-120, 120)
plt.show()

plt.plot(f, widmo_dB)
plt.xlabel('częstotliwość [Hz]')
plt.ylabel('moc [dB]')
plt.title('Skala log-log')
plt.xscale("log")
#plt.xlim(16,4000)
#plt.ylim(-120, 120)
plt.show()

plt.plot(f, widmo_dB)
plt.xlabel('częstotliwość [Hz]')
plt.ylabel('moc [dB]')
plt.title('Skala log-log dla przedziału 100Hz - 1kHz i powyżej 50dB')
plt.xscale("log")
plt.xlim(100,1000)
plt.ylim(50, 110)
```

```
plt.show()

table = scipy.io.loadmat('data/tones_data.mat') # Importujemy częstotliwości i nazwy nut
f_list = table['f'].tolist()[0] # Tworzymy listę częstotliwości
n_list = [table['n'][0].tolist()[i][0].replace(" ", "") for i in range(0,len(f_list))] #
Tworzymy listę nut + usuwamy spacje
tones_dict = dict(zip(f_list,n_list)) # Otrzymujemy słownik

start_freq = 100
stop_freq = 1000

def znajdz_piki(f, widmo_dB, start_freq, stop_freq, height, distance, tones_dict, top):

    start = int(start_freq * len(widmo_dB)/max(f))
    stop = int(stop_freq * len(widmo_dB)/max(f))

    widmo_db_cropped = widmo_dB[start:stop]
    f_cropped = f[start:stop]
    peaks, _ = find_peaks(widmo_db_cropped, height=height, distance=distance)
    plt.plot(f_cropped, widmo_db_cropped)
    plt.plot(f_cropped[peaks], widmo_db_cropped[peaks], "x")
    plt.axhline(y = height, linestyle='-', color="gray")
    plt.xlabel('częstotliwość [Hz]')
    plt.ylabel('moc [dB]')
    plt.title(f'Znalezione piki dla przedziału {start_freq}Hz - {stop_freq}Hz i powyżej
{height}dB')
    plt.xscale("log")
    plt.show()

    dzwieki = list(tones_dict.values())
    czestosci = list(tones_dict.keys())

    df = pd.DataFrame(list(zip(f_cropped[peaks], widmo_db_cropped[peaks])),
columns=['czestotliwosc_piku', 'widmo_dB'])
    df.sort_values(by = 'widmo_dB', ascending=False, inplace=True)
    df = df.iloc[:top,:]

    fitted_freq = []
    fitted_sounds = []

    for frequency in df.iloc[:,0]:
        fitted_freq.append(czestosci[min(range(len(czestosci)), key=lambda i:
abs(czestosci[i]-frequency))])
        fitted_sounds.append(dzwieki[min(range(len(czestosci)), key=lambda i:
abs(czestosci[i]-frequency))])

    df = df.assign(dop_czestotliwosc = fitted_freq)
    df = df.assign(nazwa_dzwieku = fitted_sounds)
    df.sort_values(by = 'czestotliwosc_piku', ascending=True, inplace=True)
```

```
    return(df)

piki_df = znajdz_piki(f, widmo_dB, start_freq, stop_freq, 50, 50, tones_dict, 6)
piki_df.reset_index(inplace=True, drop=True)
piki_df.to_csv('data/piki.csv')
```

3. Wyniki

Wykres na Rys. 1 przedstawia sygnał w dziedzinie czasu:

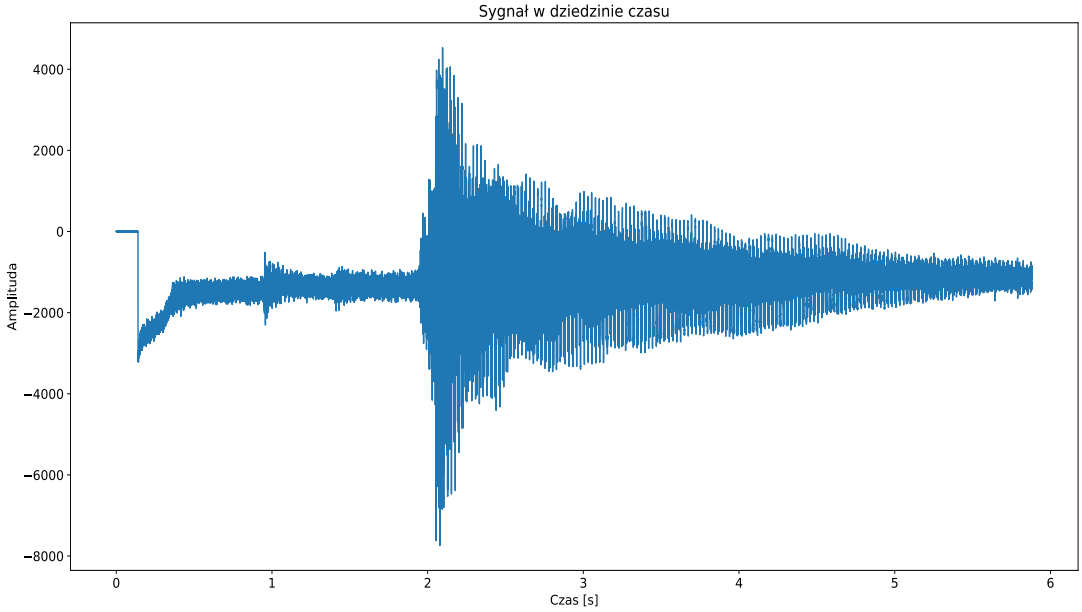

Rys. 1

Wykres na Rys. 1 przedstawia transformatę Fouriera z oknem Hamminga sygnału uciętą do częstotliwości 4kHz:

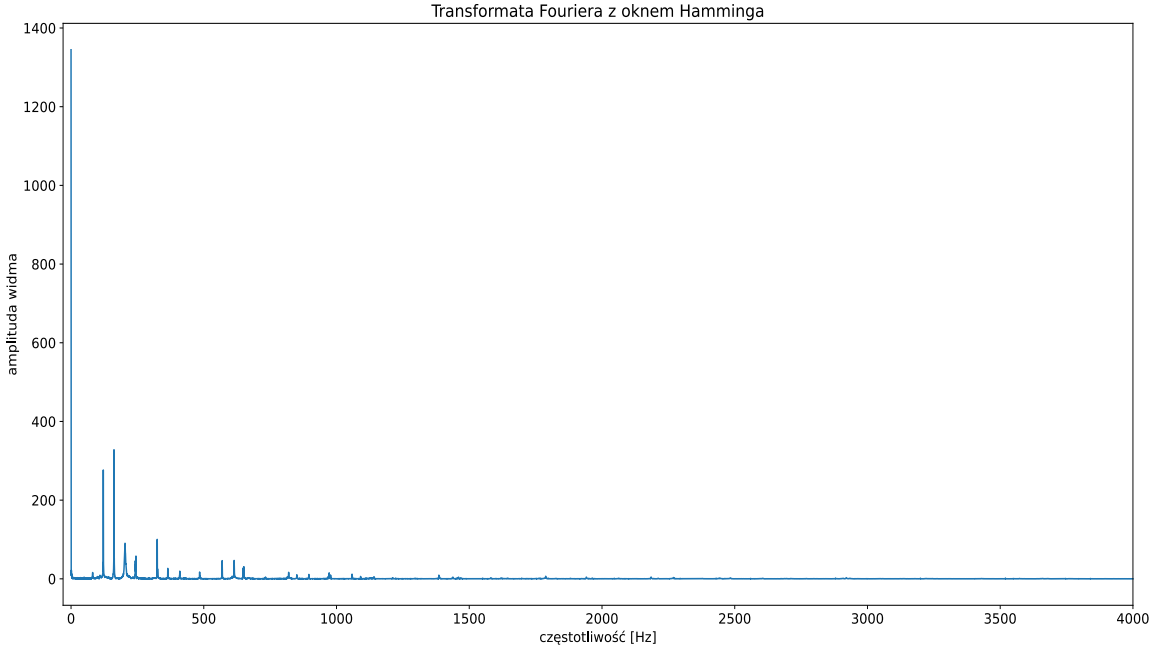

Rys. 2

Wykres na Rys. 1 przedstawia widmo mocy całego sygnału:

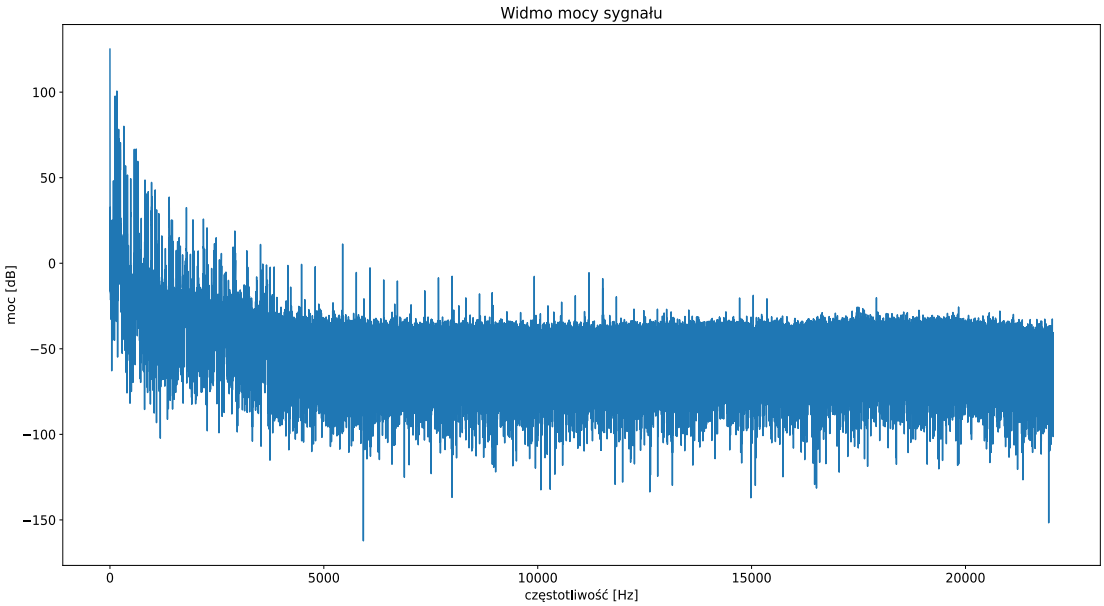

Rys. 3

Wykres na Rys. 1 przedstawia widmo mocy sygnału dla przedziału 16Hz – 4kHz:

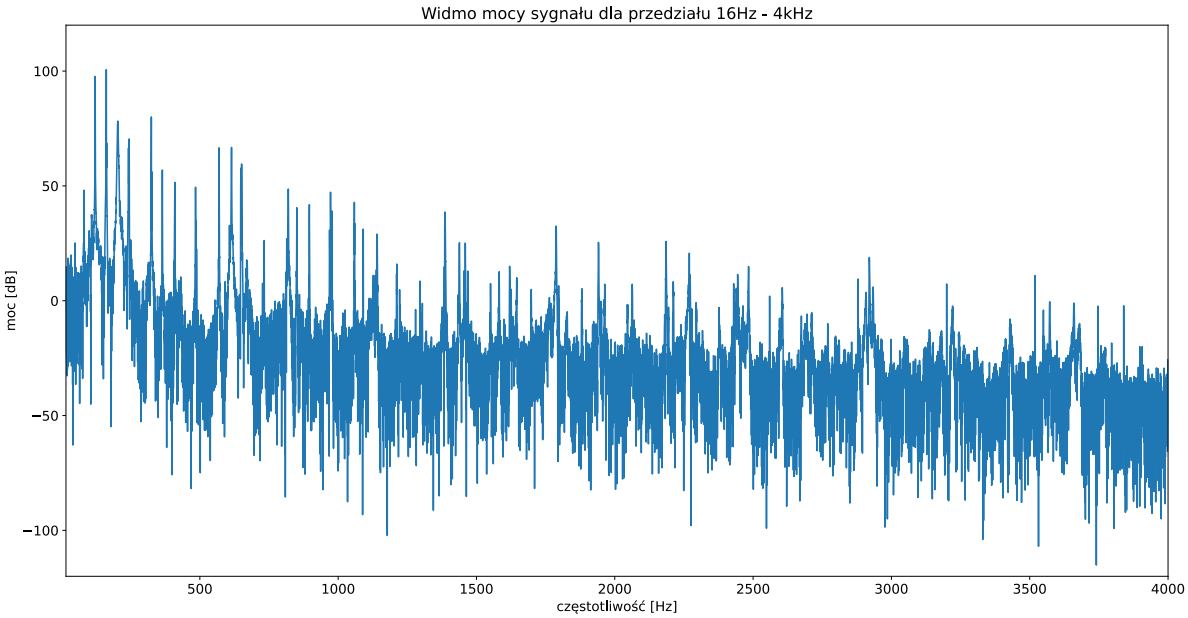

Rys. 4

Wykres na Rys. 1 przedstawia widmo mocy sygnału w skali log-log:

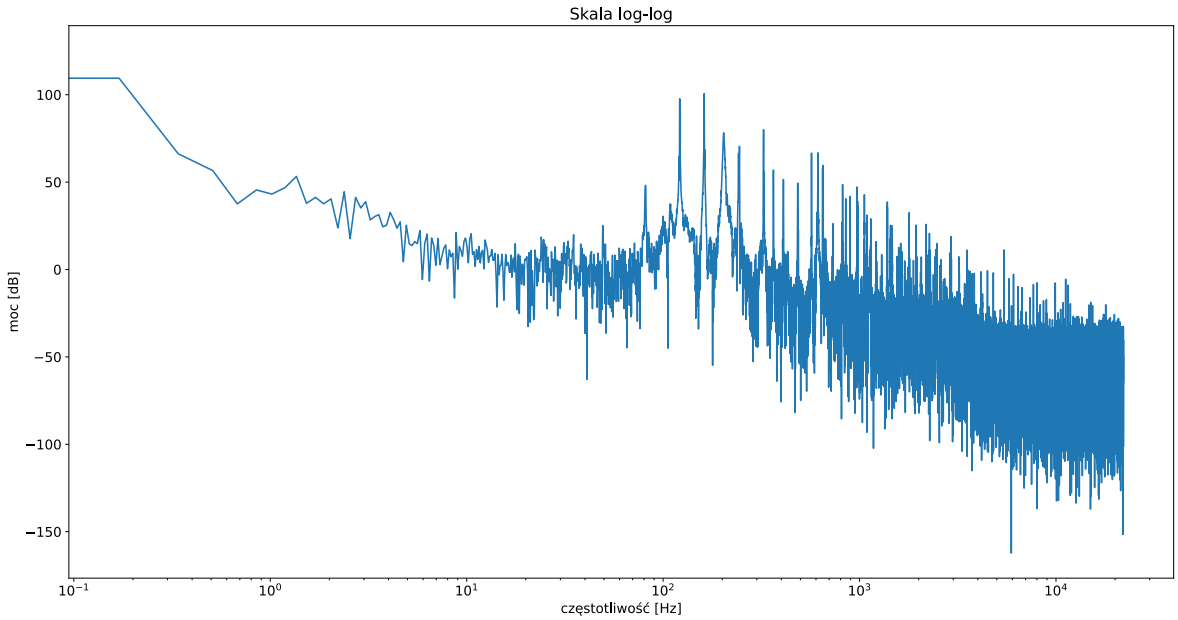

Rys. 5

Wykres na Rys. 1 przedstawia widmo mocy dla przedziału 100Hz - 1kHz z wartościami powyżej 50dB:

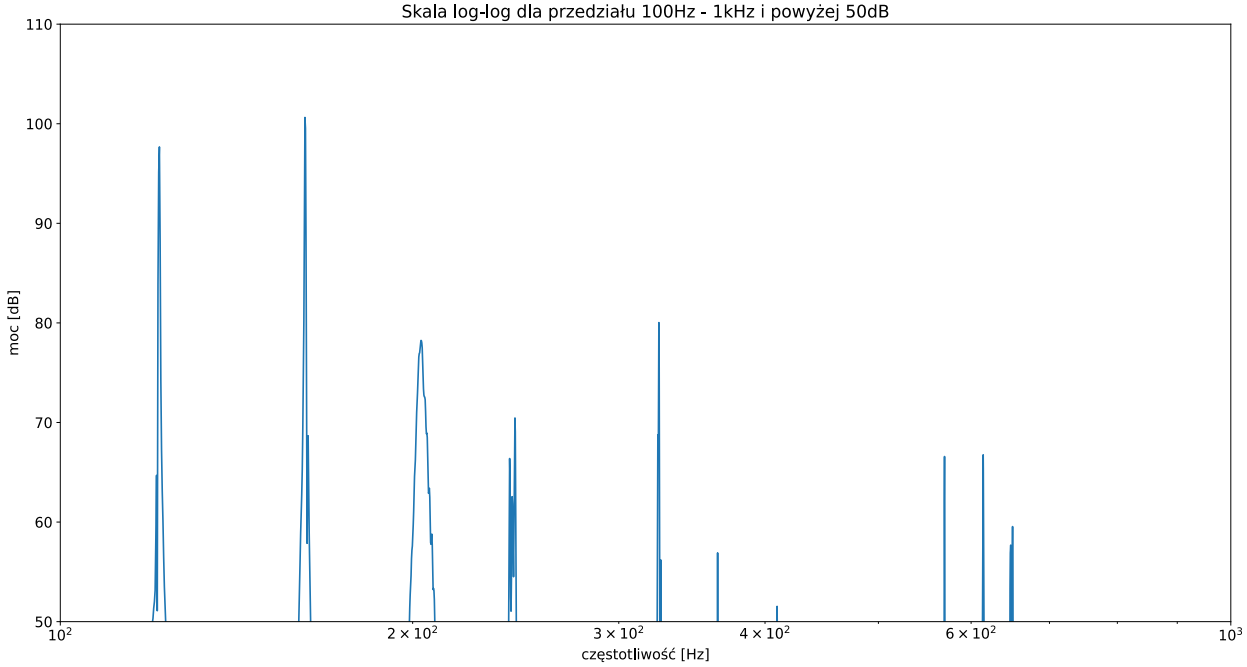

Rys. 6

Za pomocą funkcji *znajdz_piki* wyznaczono położenia położenia pików i zaznaczono na wykresie znakiem ‘x’. Wykres zwracany przez powyższą funkcję jest przedstawiony na Rys. 6. Szara linia oznacza próg wartości, powyżej którego znajdowane były piki (w tym przypadku 50dB).

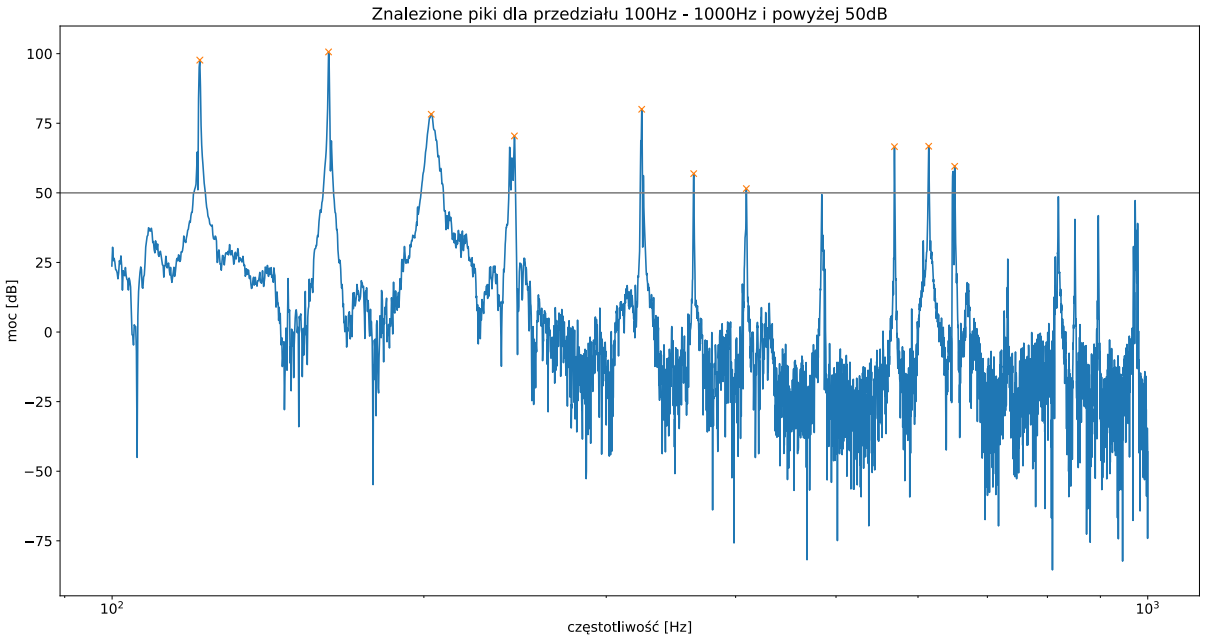

Rys. 7

Znalezione częstości (ograniczone do 6 najwyższych pików) oraz dopasowane do nich nazwy dźwięków (przy pomocy pliku *tones_data.mat*) przedstawione są w tabeli poniżej:

Częstotliwość piku [Hz]	Widmo mocy [dB]	Dopasowana częstotliwość [Hz]	Nazwa dźwięku
121,53	97,67	123,47	B2
161,81	100,63	164,81	E3
203,29	78,23	207,65	G#3
244,59	70,45	246,94	B3
324,64	80,03	329,62	E4
614,44	66,75	622,25	D#5

4. Wnioski

- Analizowana melodia jest akordem.
- Akord ten zawiera dźwięki (6 najwyższych pod względem mocy): B2, E3, G#3, B3, E4, D#5.