Bogumił Wierzchowski 291498

Analiza sygnału w dziedzinie czasu i częstości

Ćwiczenie 4: Filtry

1. Wstęp

Celem ćwiczenia jest zapoznanie się z rodzajami oraz działaniem filtrów FIR oraz IIR.

Użyte oprogramowanie: *Python ver. 3.9.7*

Użyte biblioteki: *numpy, scipy, matplotlib*

2. Kod źródłowy

```
import numpy as np
import matplotlib.pyplot as plt
import scipy.signal as sig
import scipy.io
import sys

# cd .\semestr2\ASwDCiC\lab4\
plt.rcParams['font.size'] = '13'

def signaltonoiseScipy(a, axis=0, ddof=0):
    a = np.asanyarray(a)
    m = a.mean(axis)
    sd = a.std(axis=axis, ddof=ddof)
    return np.where(sd == 0, 0, m/sd)

N = 2000
A = 5
f = 5
fs = 1000
dt = 1/fs
t = np.arange(N) * dt

x = A * np.sin(2 * np.pi * f * t) + A *np.random.normal(0, 1, N)
```

```
widmo_sygnalu = 20 * np.log10(np.abs(np.fft.rfft(x * np.hamming(N))) / N/2)
f = np.fft.rfftfreq(N, 1 / fs)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(x)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,x)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title= 'Zaszumiony sygnał
x(t), SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_sygnalu)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
zaszumionego sygnał')
plt.show()

dp_100 = sig.firwin(100, 10, fs=fs)

przefiltrowany = sig.lfilter(dp_100, 1, x)
widmo_przefiltrowany = 20 * np.log10(np.abs(np.fft.rfft(przefiltrowany *
np.hamming(N))) / N/2)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(przefiltrowany)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,przefiltrowany)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Przefiltrowany DP
sygnał x(t), SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_przefiltrowany)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
przefiltrowanego DP sygnału')
plt.show()

gp = sig.firwin(101, 100, pass_zero=False, fs=fs)

przefiltrowany = sig.lfilter(gp, 1, x)
widmo_przefiltrowany = 20 * np.log10(np.abs(np.fft.rfft(przefiltrowany *
np.hamming(N))) / N/2)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(przefiltrowany)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,przefiltrowany)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Przefiltrowany GP
sygnał x(t), SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_przefiltrowany)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
przefiltrowanego GP sygnału')
plt.show()
```

```
b, a = sig.iirfilter(8, 10 / (fs / 2), ftype='butter', btype='lowpass')

przefiltrowany = sig.lfilter(b, a, x)
widmo_przefiltrowany = 20 * np.log10(np.abs(np.fft.rfft(przefiltrowany *
np.hamming(N))) / N/2)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(przefiltrowany)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,przefiltrowany)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Przefiltrowany DP
sygnał x(t), SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_przefiltrowany)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
przefiltrowanego DP sygnału')
plt.show()

b, a = sig.iirfilter(8, 100 / (fs / 2), ftype='butter', btype='highpass')

przefiltrowany = sig.lfilter(b, a, x)
widmo_przefiltrowany = 20 * np.log10(np.abs(np.fft.rfft(przefiltrowany *
np.hamming(N))) / N/2)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(przefiltrowany)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,przefiltrowany)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Przefiltrowany GP
sygnał x(t), SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_przefiltrowany)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
przefiltrowanego GP sygnału')
plt.show()

f1 = 5
f2 = 50
y = A * np.sin(2*np.pi*f1*t)+2*np.sin(10*np.pi*f2*t)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(y)))

widmo_sygnalu = 20 * np.log10(np.abs(np.fft.rfft(y * np.hamming(N))) / N/2)
f = np.fft.rfftfreq(N, 1 / fs)

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,y)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Złożenie 2 sinusów
y(t), SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_sygnalu)
```

```
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
złożenia 2 sinusów')
plt.show()

dp_10 = sig.firwin(100, 10, fs=fs)

przefiltrowany = sig.lfilter(dp_10, 1, y)
widmo_przefiltrowany = 20 * np.log10(np.abs(np.fft.rfft(przefiltrowany *
np.hamming(N))) / N/2)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(przefiltrowany)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,przefiltrowany)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Przefiltrowany DP
sygnał y(t), SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_przefiltrowany)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
przefiltrowanego sygnał')
plt.show()

gp_200 = sig.firwin(101, 200, pass_zero=False, fs=fs)

przefiltrowany = sig.lfilter(gp_200, 1, y)
widmo_przefiltrowany = 20 * np.log10(np.abs(np.fft.rfft(przefiltrowany *
np.hamming(N))) / N/2)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(przefiltrowany)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,przefiltrowany)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Przefiltrowany GP
sygnał y(t), SNR: %.2f db' % SNRscipy, xlim=(0.5, 0.6))
ax2.plot(f, widmo_przefiltrowany)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
przefiltrowanego sygnał')
plt.show()

mat = scipy.io.loadmat('ecg.mat')
ecg = mat['ecg']

N = ecg.shape[0]
ecg = ecg.reshape(N)
fs = 500
dt = 1/fs
t = np.arange(N) * dt

widmo_ecg = 20 * np.log10(np.abs(np.fft.rfft(ecg * np.hamming(N))) / N/2)
f = np.fft.rfftfreq(N, 1 / fs)
```

```
SNRscipy = 20*np.log10(abs(signaltonoiseScipy(ecg)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,ecg)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Wczytany sygnał
$\it{ecg.mat}$, SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_ecg)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
sygnału')
plt.show()

dp_40 = sig.firwin(100, 40, fs=fs)

przefiltrowany = sig.lfilter(dp_40, 1, ecg)
widmo_przefiltrowany = 20 * np.log10(np.abs(np.fft.rfft(przefiltrowany *
np.hamming(N))) / N/2)

gp_8 = sig.firwin(101, 8, pass_zero=False, fs=fs)

przefiltrowany = sig.lfilter(gp_8, 1, przefiltrowany)
widmo_przefiltrowany = 20 * np.log10(np.abs(np.fft.rfft(przefiltrowany *
np.hamming(N))) / N/2)

SNRscipy = 20*np.log10(abs(signaltonoiseScipy(przefiltrowany)))

fig, (ax1, ax2) = plt.subplots(2, 1)
ax1.plot(t,przefiltrowany)
ax1.set(xlabel='Czas [s]', ylabel='amplituda [a.u.]', title='Przefiltrowany sygnał
$\it{ecg.mat}$, SNR: %.2f db' % SNRscipy)
ax2.plot(f, widmo_przefiltrowany)
ax2.set(xlabel='Częstotliwość [Hz]', ylabel='amplituda [dB]', title='Widmo
przefiltrowanego sygnał')
plt.show()
```

3. Wyniki

Zaszumiony sygnał postaci: $x(t) = 5 \cdot \sin(10\pi t) + 5 \cdot norm(t)$ oraz jego widmo, gdzie $norm(t)$ oznacza losową wartość w chwili t wylosowaną ze standardowego rozkładu normalnego, przedstawia wykres poniżej:

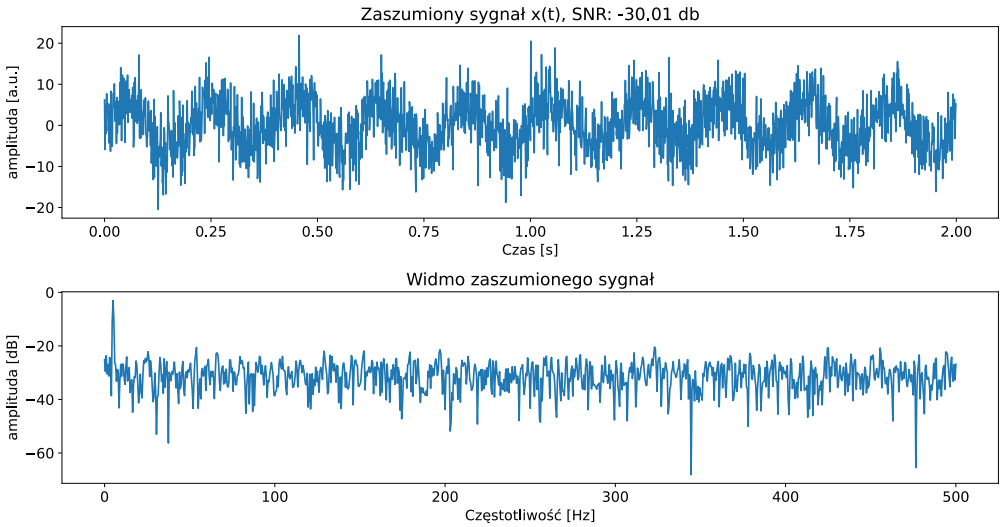

Przefiltrowany sygnał $x(t)$ (oraz jego widmo) filtrem FIR dolnoprzepustowym o długości $L = 100$ i częstotliwości granicznej 10Hz, przedstawia wykres poniżej:

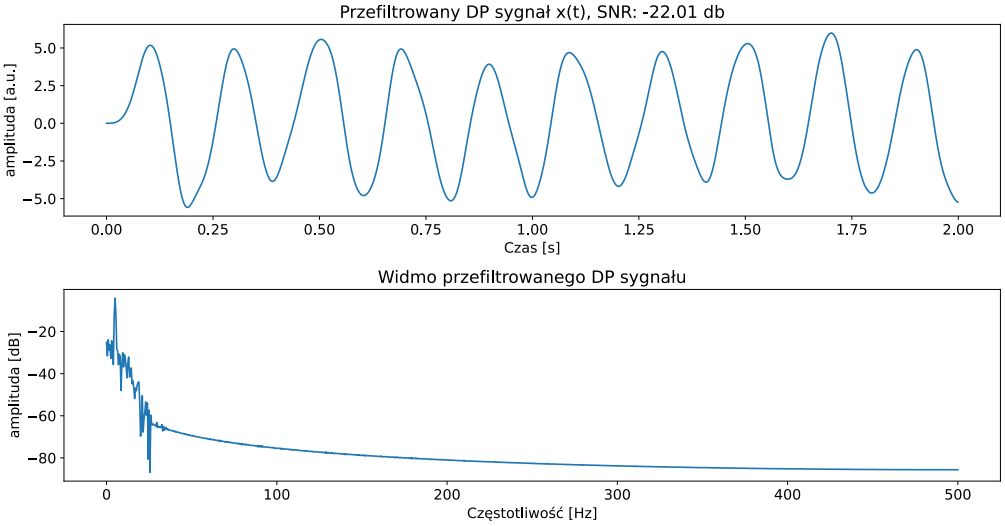

Przefiltrowany sygnał $x(t)$ (oraz jego widmo) filtrem FIR górnoprzepustowym o długości $L = 101$ i częstotliwości granicznej 100Hz, przedstawia wykres poniżej:

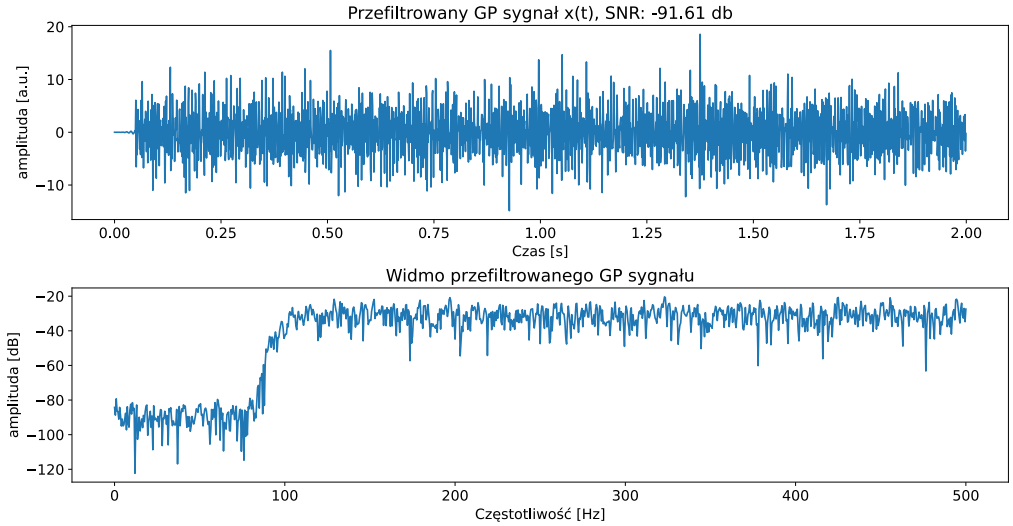

Przefiltrowany sygnał $x(t)$ (oraz jego widmo) filtrem IIR (Butterwortha) dolnoprzepustowym o rzędzie $N = 8$ i częstotliwości granicznej 10Hz, przedstawia wykres poniżej:

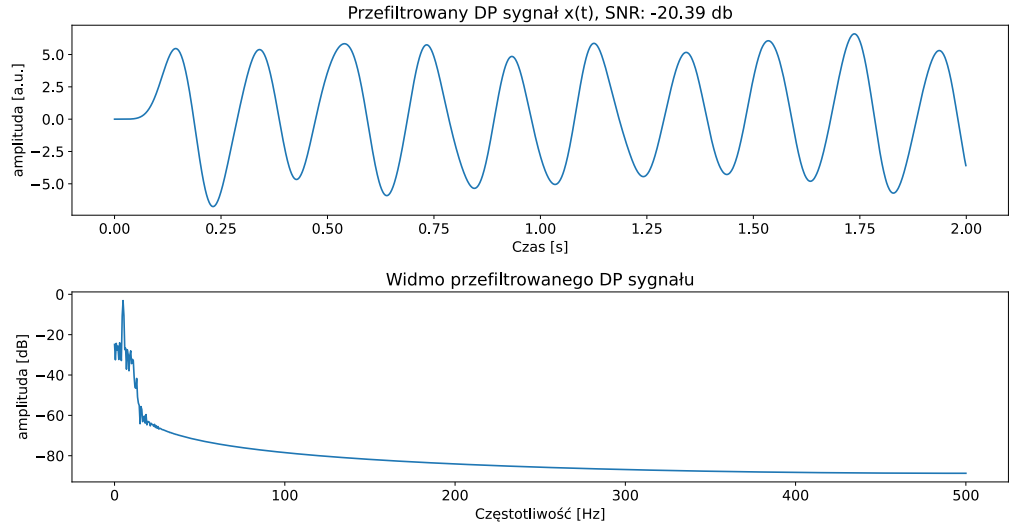

Przefiltrowany sygnał $x(t)$ (oraz jego widmo) filtrem IIR (Butterwortha) górnoprzepustowym o rzędzie $N = 8$ i częstotliwości granicznej 100Hz, przedstawia wykres poniżej:

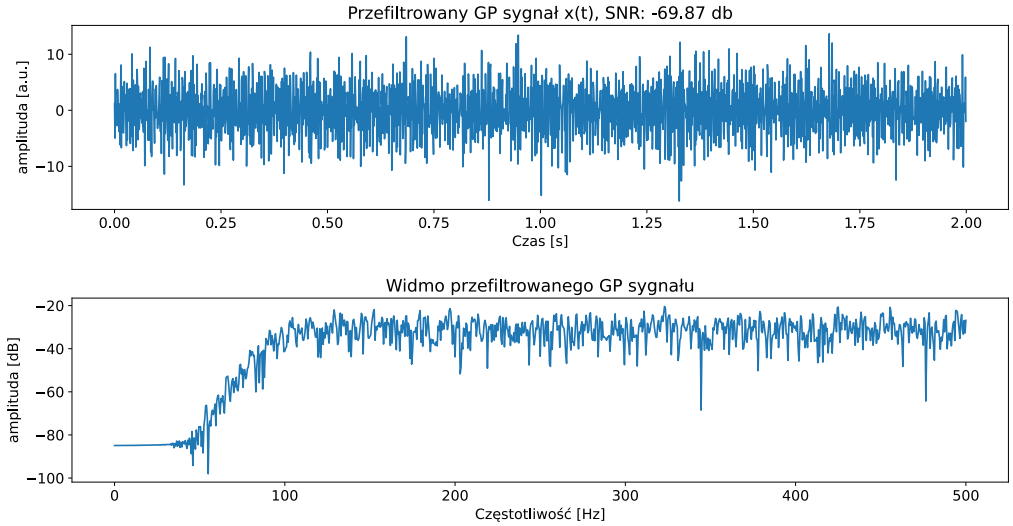

Złożenie 2 sinusów postaci: $y(t) = 5 \cdot \sin(10\pi t) + 2 \cdot \sin(500\pi t)$ oraz ich widmo, przedstawia wykres poniżej:

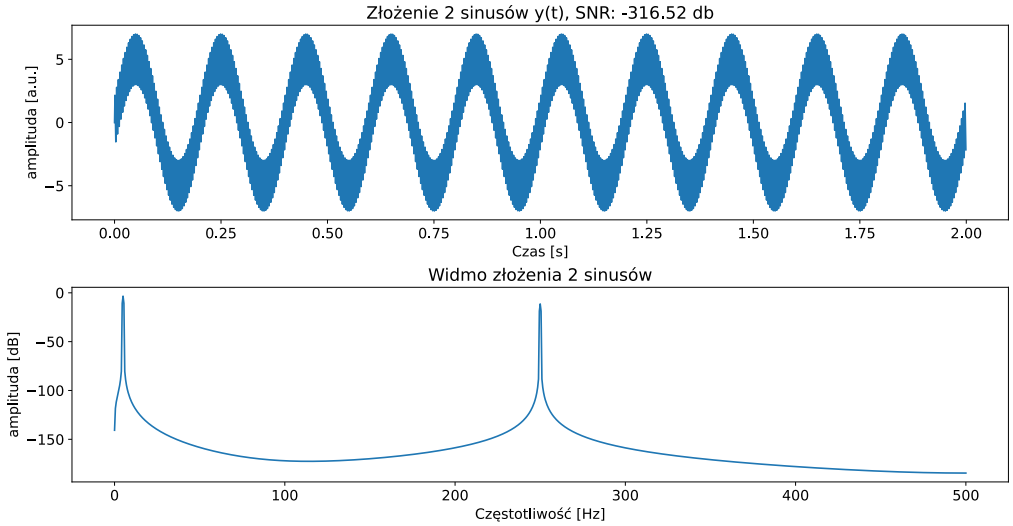

Przefiltrowany sygnał $y(t)$ dolnoprzepustowym filtrem FIR o częstotliwości odcięcia 10Hz oraz jego widmo, przedstawia wykres poniżej:

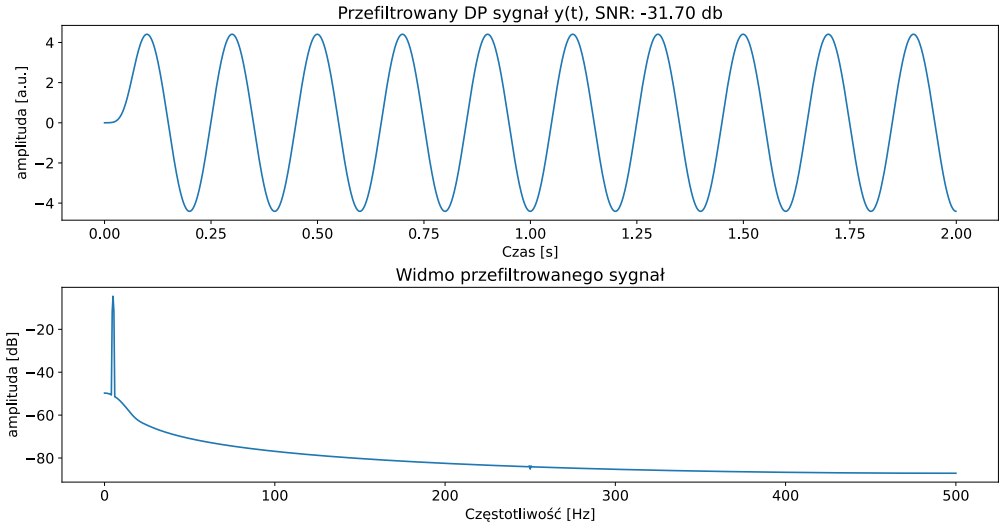

Przefiltrowany sygnał $y(t)$ górnoprzepustowym filtrem FIR o częstotliwości odcięcia 200Hz oraz jego widmo, przedstawia wykres poniżej:

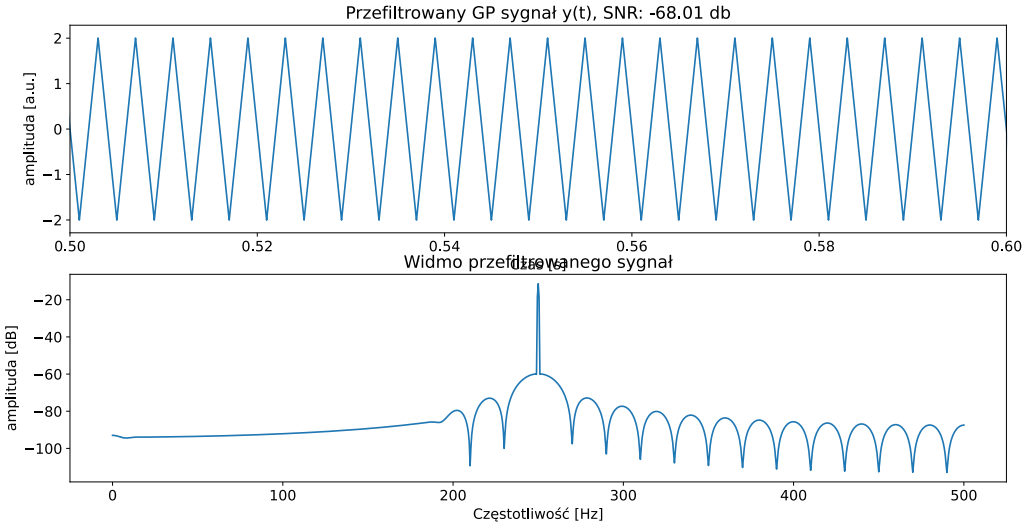

Wczytany sygnał *ecg.mat* oraz jego widmo przedstawia wykres poniżej:

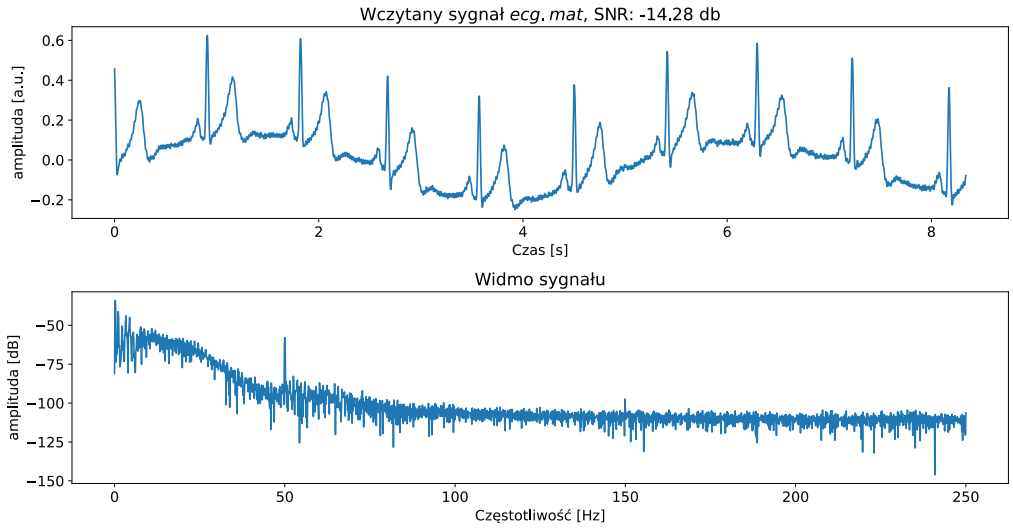

Przefiltrowany najpierw dolnoprzepustowo ($f_c = 40Hz$) a następnie górnoprzepustowo ($f_c = 8Hz$) sygnał *ecg.mat* oraz jego widmo przedstawia wykres poniżej (oba filtry FIR):

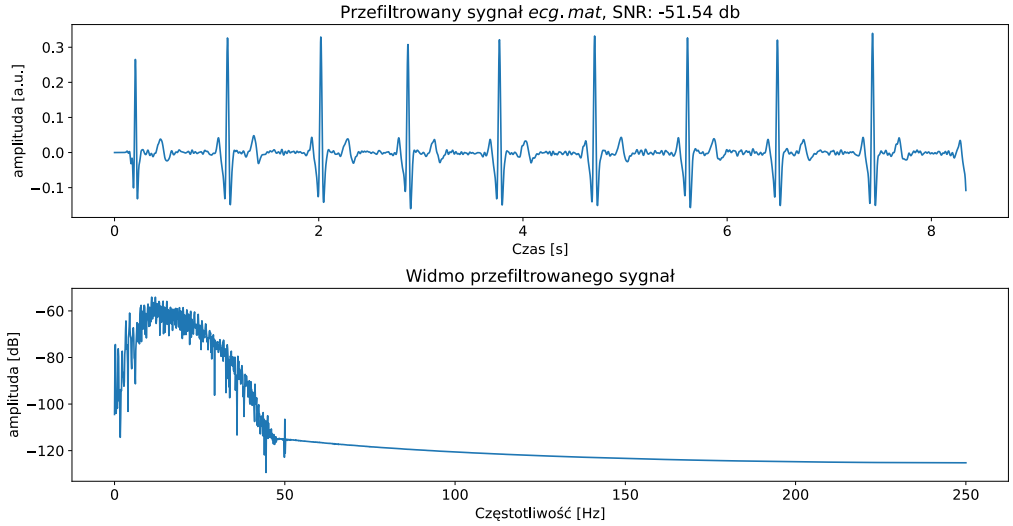

Filtry zostały dobrane tak aby wyciąć zakłócenia sieci elektrycznej o częstotliwości 50Hz oraz falowanie sieci bazowej o częstotliwości < 8Hz.

4. Wnioski

- Filtry typu FIR oraz IIR można wykorzystać do analizy sygnału EKG.
- Filtry górnoprzepustowe tłumią częstotliwości niże od granicznej a przepuszczają te wyższe.
- Filtry dolnoprzepustowe tłumią częstotliwości wyższe od granicznej a przepuszczają te niższe.
- Zarówno filtry FIR jak i IIR nie są idealne, nie zapewniają idealnego tłumienia powyżej częstotliwości odcięcia lecz istnieje pewne pasmo przejściowe.
- Sygnały analityczne lepiej poddają się filtracji niż te rzeczywiste.